ПЛАН МАГИСТЕРСКОГО ИССЛЕДОВАНИЯ

Разработка ресурсоэффективного фреймворка латентной диффузии для синтеза медицинских изображений

Title (EN): Development of a Resource-Efficient Latent Diffusion Framework for Medical Image Synthesis

Тақырып (KZ): Медициналық кескіндерді синтездеуге арналған ресурстық тиімді латентті диффузиялық фреймворкты әзірлеу

Параметр	Содержание
Магистрант	Кубесов Ерлан (Kubesov Erlan)
Группа / программа	AAI-2605M / Applied Artificial Intelligence
Научный руководитель	Ryspayeva Marya, PhD, Assistant Professor
Статус	Предварительный исследовательский план; архитектура уточняется после пилотных экспериментов

1. Идея, цель и исследовательский вопрос

Идея: генерировать синтетические 2D КТ-срезы органов брюшной полости, моделируя процесс диффузии не в пикселях, а в компактном латентном пространстве автоэнкодера. Исследование посвящено достижению разумного соотношения качества синтеза и вычислительных затрат, а не клиническому созданию новых исследований КТ.

Цель: разработать и экспериментально оценить воспроизводимый ресурсоэффективный latent diffusion framework и определить, как изменение латентного сжатия, режима обучения и числа шагов генерации влияет на качество и стоимость синтеза.

- RQ1: насколько latent diffusion дешевле pixel-space DDPM при сопоставимых изображениях и одинаковом аппаратном обеспечении?
- RQ2: какой компромисс между качеством VAE-реконструкции, качеством синтеза и скоростью обеспечивает коэффициент сжатия?
- RQ3: улучшает ли адаптивное распределение обучающих шагов по уровням шума качество при фиксированном числе итераций?

2. Основной бесплатный датасет — OrganAMNIST (MedMNIST+)

Параметр	Характеристика
Изображения	2D аксиальные КТ-срезы органов; grayscale, 11 классов анатомических областей
Объём	34 561 train / 6 491 validation / 17 778 test (всего 58 830 изображений)
Разрешение	Начать с OrganAMNIST 64×64; основной целевой вариант — 128×128
Доступ	Открытый официальный архив Zenodo; бесплатно, файл .npz, без исследовательской заявки
Условия	В метаданных проекта указано CC BY 4.0; необходимо цитирование и проверка условий исходных материалов
Формат	train_images, train_labels, val_images, val_labels, test_images, test_labels

Официальный архив: https://zenodo.org/records/10519652

Прямая загрузка 64×64: https://zenodo.org/records/10519652/files/organamnist_64.npz?download=1

Прямая загрузка 128×128: https://zenodo.org/records/10519652/files/organamnist_128.npz?download=1

Ограничения: это стандартизованные уменьшенные 2D изображения, а не исходные полноразмерные DICOM КТ. Они не предназначены для медицинской интерпретации. 2D-срезы могут происходить из связанных объёмов; официальные split нельзя автоматически трактовать как доказанно независимые по пациентам. Проверить описание происхождения и доступные идентификаторы; при невозможности проверки честно указать ограничение.

3. Модели и компоненты фреймворка

Вариант	Архитектура / роль
Контроль A: pixel DDPM	Небольшой U-Net с диффузией непосредственно по пикселям, разрешение 64×64; контроль стоимости.
Компонент VAE	Сверточный encoder/decoder, KL-регуляризованный либо VAE-аналог; обучается только на train, проверяется на validation.

Контроль B: standard LDM	VAE encoder → латентный U-Net/DDPM → VAE decoder; одинаковый датасет и фиксированный бюджет шагов.
Основной предлагаемый вариант	Budget-aware LDM: тот же VAE и U-Net, но адаптивный sampling уровней шума при обучении + фиксированный бюджет итераций.
Инференс	DDPM/DDIM scheduler; отдельное сравнение 25/50/100 шагов генерации; варианты фиксировать до test.
Опционально	Conditioning по метке органа (class embedding); только после воспроизведения unconditional LDM.

Критическое уточнение: латентная диффузия, DDIM и importance sampling по timesteps уже существуют. Возможный вклад — воспроизводимое бюджетное правило и обоснованный Pareto-анализ на конкретном медицинском наборе; нельзя выдавать отдельный известный компонент за новый алгоритм.

4. Предлагаемая модификация и проверяемая гипотеза

Рабочее название: Compute-Budget-Aware Timestep Sampling (CBATS). Сохранить архитектуру U-Net, кодировщик VAE и количество обновлений оптимизатора; менять только частоту выбора уровней шума при обучении. Поддерживать скользящую оценку ошибки денойзинга по корзинам timesteps и плавно увеличивать вероятность выборки сложных корзин с ненулевым равномерным компонентом. При смещённой выборке использовать корректные веса (importance correction) либо явно обозначить изменение учебной цели.

Гипотеза: при одинаковом числе GPU-часов такое распределение шагов может улучшить качество синтеза относительно равномерного выбора timesteps, особенно при ограниченном бюджете. Результат может быть отрицательным.

- Ablation 1: равномерный sampling → фиксированный неравномерный sampling → адаптивный sampling.
- Ablation 2: сравнить VAE-сжатие ×4 и ×8 только при приемлемом качестве реконструкции и реальной доступности вычислительных ресурсов.
- Показать отдельно эффект обучения (GPU-hours) и ускорение генерации (DDIM 25/50/100); не приписывать ускорение DDIM новой модели.

5. Протокол и защита от некорректного сравнения

- Официальные train/val/test сохранить; не обучать VAE, генератор или feature-extractor для оценки на test. Проверить точные/визуально близкие повторы и источники срезов.
- Начать с 64×64, тестировать пайплайн, затем согласовать фиксированную основную постановку на 128×128. Сравнения по качеству проводить на одинаковом разрешении.
- Обучать VAE на train; выбирать сжатие, эпохи и scheduler по validation. Зафиксировать конфигурации и seeds (не менее трёх для ключевых сравнений по возможности).
- DDPM pixel baseline и latent варианты должны иметь прозрачный бюджет: число GPU-часов, шагов оптимизатора, batch size, число параметров и оборудование. Равное число шагов не означает равную стоимость — сообщать оба режима сравнения.
- Генерировать одинаковое число изображений и использовать одинаковую сеть извлечения признаков для FID/KID; test не применять для выбора конфигураций. Реальные test изображения использовать только для заранее определённой итоговой оценки.
- Оценить риск запоминания: nearest-neighbor сходство с train, дубликаты, возможные совпадения генераций с исходными срезами. Синтетические данные не объявлять анонимными по умолчанию.

6. Метрики и экспериментальная матрица

Эксперимент	Что проверяем
E0	Pixel DDPM 64×64 — контроль генерации и затрат.
E1	Стандартная LDM с uniform timestep sampling.
E2	Та же LDM + фиксированный неравномерный sampling (контроль).
E3 — основной	Та же LDM + адаптивный sampling по EMA loss.
E4 — дополнительно	E1/E3 при другом латентном сжатии или классовой условности, если есть ресурсы.

Качество: KID (предпочтительно при небольших выборках), FID с явно указанным feature extractor, precision/recall генерации; для VAE — MAE/SSIM реконструкции. Inception features обучены на естественных изображениях и недостаточно отражают медицинскую достоверность: добавить доменно-релевантный extractor, визуальный аудит и ограничения метрик.

Эффективность: GPU-hours обучения, пиковая VRAM, число параметров, время/изображение, images/sec, затраты на 1 000 генераций при фиксированном batch size. Отобразить quality–compute Pareto frontier. Измерять на одинаковом GPU и ПО.

7. Границы работы и ожидаемые результаты

- Репозиторий Python/PyTorch + diffusers с независимыми модулями: загрузка данных → VAE → LDM → sampler → генерация → оценка → отчёт.
- Таблицы E0–E3, визуальные сетки реальных/синтетических образцов, графики качества и расхода ресурсов, проверка memorization.
- Вывод: при каких бюджетах и разрешениях модификация полезна или не полезна. Не утверждать клиническую пригодность или улучшение диагностики без независимого downstream-эксперимента.
- Необязательно: отдельный эксперимент полезности синтетических изображений для классификатора, обученного на реальных данных; синтетика только из train и не должна попадать в test.

8. Поэтапный план

Этап	Артефакт
1. Литература	Обзор LDM/DDPM/DDIM и бюджетного обучения (10–15 работ); уточнённая новизна.
2. Аудит	Скачанный OrganAMNIST, разбиения, сводка классов, проверки дубликатов.
3. Базовые модели	Pixel DDPM, VAE, standard LDM, первые изображения и профили GPU.
4. Модификация	CBATS + контролируемые E1–E3 и ablation.
5. Проверка	FID/KID, latency, VRAM, Pareto, seeds, запоминание и анализ ошибок.
6. Защита	Чистый код, README, веса/конфиги, главы диссертации, потенциальная статья.

9. Минимально достаточная работа и стартовые действия

Минимум: OrganAMNIST 64×64 (128×128 при доступности GPU), VAE, pixel DDPM, standard LDM, E3 с одним обоснованным изменением, единая таблица качества и вычислительных затрат, ≥3 seed для основного сопоставления при реалистичном бюджете. Полная генерация объёмной 3D КТ, обучение Stable Diffusion с нуля и клинические выводы не требуются.

- Скачать organamnist_64.npz, напечатать формы массивов и распределения 11 классов.
- Обучить маленький VAE, показать реальные изображения рядом с реконструкциями.
- Сделать первый DDPM и LDM на 64×64, замерить память и время на одинаковом устройстве.
- После пилота согласовать одну конкретную модификацию и экспериментальный бюджет.

10. Официальные ссылки и литература

MedMNIST+ (Zenodo): https://zenodo.org/records/10519652

MedMNIST официальный репозиторий и info.py: https://github.com/MedMNIST/MedMNIST

Yang et al. MedMNIST v2. Scientific Data (2023): https://doi.org/10.1038/s41597-022-01721-8

Rombach et al. High-Resolution Image Synthesis with Latent Diffusion Models. CVPR 2022: https://openaccess.thecvf.com/content/CVPR2022/html/Rombach_High-Resolution_Image_Synthesis_With_Latent_Diffusion_Models_CVPR_2022_paper.html

Ho et al. Denoising Diffusion Probabilistic Models: https://arxiv.org/abs/2006.11239

Song et al. Denoising Diffusion Implicit Models: https://arxiv.org/abs/2010.02502

Hugging Face Diffusers: https://huggingface.co/docs/diffusers/main/en/index